

Enseignant : Ali Saidi



Mini-Projet : Analyse des Ventes E-Commerce

Intégration pratique : NumPy • Pandas • Matplotlib • Seaborn

NIVEAU
Intermédiaire

DURÉE ESTIMÉE
1h 30m - 2h 00m

LIVRABLE
Script / Notebook Python

Objectif du TP : Simuler un jeu de données de transactions e-commerce avec NumPy, effectuer le nettoyage et les calculs analytiques avec Pandas, puis concevoir un tableau de bord graphique complet avec Matplotlib et Seaborn.

ÉTAPE 1 – SIMULATION DES DONNÉES BRUTES NumPy

Exercice 1 – Génération vectorielle

À l'aide de la librairie numpy, simuler les données brutes de **500 commandes** :

- Fixer la graine aléatoire à 42 (`np.random.seed(42)`) pour rendre les résultats répliquables.
- `Commande_ID` : Identifiants uniques allant de 1001 à 1500.
- `Prix_Unitaire` : 500 valeurs tirées d'une distribution uniforme entre 15 € et 150 € (arrondies à 2 décimales).
- `Quantite` : 500 entiers aléatoires entre 1 et 5 unités.
- `Frais_Livraison` : 500 valeurs tirées d'une distribution normale (moyenne = 8.0, écart-type = 2.0). Utiliser `np.abs()` pour éviter les valeurs négatives.
- `Satisfaction_Client` : 500 entiers aléatoires de 1 à 5. Introduire artificiellement ~5% de valeurs manquantes (`np.nan`).

ÉTAPE 2 – STRUCTURATION ET NETTOYAGE Pandas

Exercice 2 – Construction du DataFrame et Imputation

- Convertir les tableaux NumPy en un DataFrame Pandas nommé `df_ventes`.
- Ajouter deux colonnes catégorielles tirées aléatoirement :
 - `Categorie`: ["Électronique", "Vêtements", "Maison", "Livres"]
 - `Mode_Livraison`: ["Standard", "Express", "Point Relais"]
- Créer une colonne calculée :
`Montant_Total = (Prix_Unitaire * Quantite) + Frais_Livraison`
- **Traitement des données manquantes** : Remplacer les valeurs NaN de la colonne `Satisfaction_Client` par la médiane calculée par catégorie de produit.

ÉTAPE 3 — ANALYSES STATISTIQUES Pandas & NumPy

Exercice 3 — Agrégations et Métriques clés

Répondre aux questions suivantes en utilisant les fonctions d'agrégation de Pandas et NumPy :

1. Quel est le **Chiffre d'Affaires (CA) total** généré par l'ensemble des commandes ?
2. Quelle catégorie de produit génère le plus gros chiffre d'affaires ? (Utiliser groupby).
3. Calculer le panier moyen (Montant_Total moyen) selon le Mode_Livraison.
4. À l'aide de `np.percentile()`, calculer les 25e, 50e (médiane) et 75e percentiles du Montant_Total.

ÉTAPE 4 — TABLEAU DE BORD GRAPHIQUE Matplotlib & Seaborn

Exercice 4 — Visualisation Multi-Graphiques (2x2)

Créer une figure unique composée de 4 sous-graphiques (`plt.subplots(2, 2, figsize=(14, 10))`):

- **Graphique 1 (Haut-Gauche) — Seaborn** : Un barplot représentant le CA Total par Categorie.
- **Graphique 2 (Haut-Droite) — Seaborn** : Un boxplot comparant la distribution du Montant_Total selon le Mode_Livraison.
- **Graphique 3 (Bas-Gauche) — Matplotlib / Seaborn** : Un histogramme (`histplot`) avec courbe KDE de la distribution des Frais_Livraison.
- **Graphique 4 (Bas-Droite) — Seaborn** : Une heatmap de la matrice de corrélation entre toutes les variables numériques.

Exigence de présentation : Chaque sous-graphique doit comporter un titre clair, des étiquettes sur les axes et une palette de couleurs soignée.

ÉTAPE 5 — RAPPORT DE SYNTHÈSE Interprétation

Exercice 5 — Rédaction des conclusions Data Analyst

Rédiger un court bilan synthétique (3 à 5 lignes) analysant vos visualisations :

- Existe-t-il une corrélation forte entre le montant total de la commande et la satisfaction client ?
- Quel mode de livraison offre le panier moyen le plus élevé ?
- Recommandation stratégique basée sur les résultats.

